Modelo Generativo (VAE) para o Fashion-MNIST

Disciplina: Introdução às Redes Neurais Artificiais

Autor(es): Enzo Rosim (RA: 187389)

Repositório / Código Reprodutível: https://github.com/EnzoRosim/Projeto_Generativo

1. Configuração Experimental e Reprodutibilidade

1.1. Dados e Partição

Foi utilizado o Fashion-MNIST (imagens 28×28 em tons de cinza, 10 classes). Os 60.000 exemplos de treino oficiais foram divididos aleatoriamente em **55.000 para treino** e **5.000 para validação**, com semente fixa (42). Os **10.000 exemplos oficiais de teste** foram mantidos separados. A validação foi usada para *early stopping*, escolha da melhor época e comparação de topologias na busca; o teste foi avaliado uma única vez ao final do treino de cada modelo.

Os pixels foram escalados para $[0, 1]$ (divisão por 255), sem padronização estatística. Como nenhum parâmetro de escalonamento é estimado a partir dos dados, não há risco de vazamento (*data leakage*). Os rótulos não participam do treino; são usados apenas para colorir os gráficos e calcular as métricas de análise do espaço latente.

1.2. Arquitetura e Função de Custo

O VAE é composto por MLPs com ativação ReLU. O *encoder* recebe a imagem achatada (784 entradas), passa por camadas ocultas e termina em duas cabeças lineares, que produzem μ e $\log \sigma^2$ de dimensão z (2 ou 8). A amostragem usa a reparametrização $\mathbf{z} = \mu + \sigma \odot \varepsilon$, com $\varepsilon \sim \mathcal{N}(0, I)$. O *decoder* espelha a topologia do encoder e produz 784 *logits*, transformados por sigmoide apenas na visualização.

O custo é o ELBO negativo, com $\beta = 1$, somado sobre os pixels e médio por imagem:

$$\mathcal{L}(x) = \underbrace{-\sum_{i=1}^{784} \left[x_i \log \hat{x}_i + (1 - x_i) \log(1 - \hat{x}_i) \right]}_{\text{reconstrução (BCE)}} + \underbrace{\frac{1}{2} \sum_{j=1}^{z} \left(\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1 \right)}_{D_{KL}(q(\mathbf{z}|x) \,\|\, \mathcal{N}(0,I))} . \tag{1}$$

1.3. Busca de Hiperparâmetros e Modelos Selecionados

A busca foi feita separadamente para $z = 2$ e $z = 8$, por busca aleatória: foram sorteadas 8 das 12 combinações do grid, cada uma treinada por até 15 épocas, e a escolha foi pelo **menor custo de validação**. O modelo selecionado foi então retreinado por até 50 épocas. A Tabela 1 resume o espaço explorado e as configurações escolhidas.

Table 1: Espaço amostrado e configuração selecionada para cada espaço latente.

Hiperparâmetro	**Valores Explorados**	**Escolhido** ($z = 2$)	**Escolhido** ($z = 8$)
Topologia (encoder)	[256], [512, 256], [512, 256, 128]	512–256–128	512–256
Taxa de aprendizado	10^{-3}, 5×10^{-4}	10^{-3}	5×10^{-4}
Tamanho do lote	128, 256	128	128
Otimizador	Adam (fixo)	Adam	Adam
Função de ativação	ReLU (fixa)	ReLU	ReLU
Critério de parada	*Early stopping* no custo de validação	Paciência = 8	Paciência = 8
Semente aleatória	Fixa	42	42

As Tabelas 2 e 3 mostram as 8 combinações testadas (as mesmas para os dois valores de z, pois o sorteio usa a mesma semente), ordenadas pelo custo de validação após até 15 épocas. As 4 combinações do grid que não foram sorteadas são: [256] com $\eta = 10^{-3}$ (lotes 128 e 256), [512, 256] com $\eta = 10^{-3}$ e lote 128, e [512, 256, 128] com $\eta = 5 \times 10^{-4}$ e lote 128.

Table 2: Busca de hiperparâmetros para $z = 2$, ordenada pelo custo de validação.

#	Topologia (encoder)	η	Lote	Custo (val.)
1	**512–256–128**	$\mathbf{10^{-3}}$	**128**	**256,03**
2	512–256–128	10^{-3}	256	258,20
3	512–256	10^{-3}	256	258,52
4	512–256	5×10^{-4}	128	258,90
5	512–256–128	5×10^{-4}	256	260,17
6	512–256	5×10^{-4}	256	261,10
7	256	5×10^{-4}	128	265,67
8	256	5×10^{-4}	256	268,09

Table 3: Busca de hiperparâmetros para $z = 8$, ordenada pelo custo de validação.

#	Topologia (encoder)	η	Lote	Custo (val.)
1	**512–256**	$\mathbf{5 \times 10^{-4}}$	**128**	**240,13**
2	512–256	10^{-3}	256	240,86
3	512–256	5×10^{-4}	256	241,88
4	512–256–128	10^{-3}	128	243,45
5	256	5×10^{-4}	128	244,83
6	512–256–128	10^{-3}	256	244,99
7	512–256–128	5×10^{-4}	256	245,03
8	256	5×10^{-4}	256	246,82

Alguns padrões aparecem nos resultados. A topologia com uma única camada oculta ([256]) ficou nas últimas posições em ambos os casos. Para a mesma topologia e taxa de aprendizado, o lote de 128 superou o de 256 em todos os pares comparáveis, por 1,5 a 2,4 nats; com um número fixo de épocas, o lote menor realiza mais atualizações de pesos, o que é uma explicação plausível, mas não foi testada isoladamente. Para $z = 8$, a diferença entre os dois primeiros colocados é de apenas 0,73 nat, pequena demais para sustentar a superioridade de um sobre o outro numa execução única. Por fim, os custos da busca (até 15 épocas) são maiores que os dos modelos finais (Tabela 4), como esperado pelo menor número de épocas.

2. Dinâmica de Treinamento e Convergência

A evolução do custo (ELBO negativo) de treino e validação ao longo das épocas é mostrada na Figura 1. O custo final dos modelos selecionados está na Tabela 4.

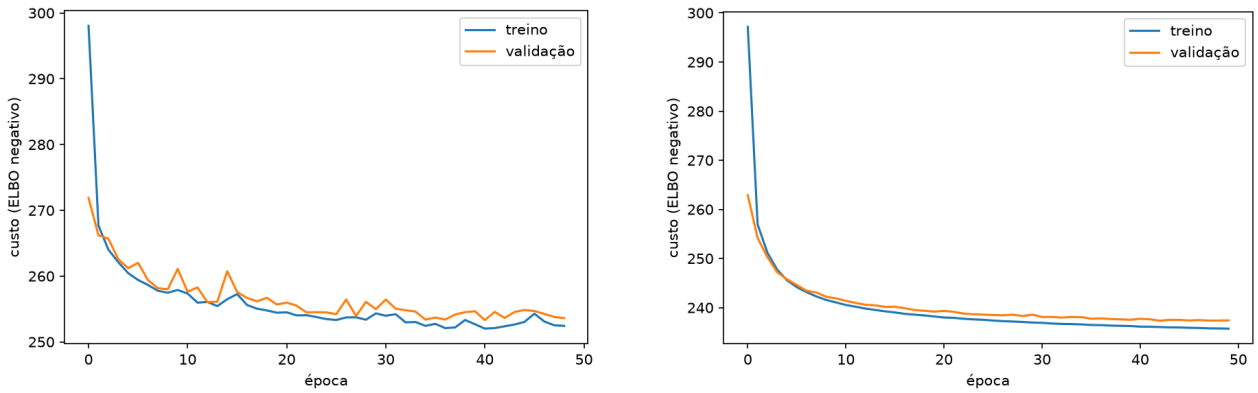


Figure 1: Custo de treino e validação por época. Esquerda: $z = 2$. Direita: $z = 8$.

Table 4: Custo (ELBO negativo médio por imagem, em nats) dos modelos selecionados.

z	Validação	Teste	Reconstrução	KL total	Dims. ativas
2	253,32	254,01	246,74	7,27	2 de 2
8	237,32	238,40	225,19	13,21	7 de 8

Reconstrução = custo de teste − KL. Dimensão ativa: variância de $\mu > 0{,}01$.

Análise da Dinâmica de Convergência:

- **Generalização:** o custo de teste ficou apenas cerca de 0,7 nat (z=2) e 1,1 nat (z=8) acima do de validação, o que indica que a seleção de hiperparâmetros pela validação não distorceu o resultado final.
- **Convergência e sobreajuste:** para $z = 2$, o treino durou 49 épocas e o menor custo de validação ocorreu na época 41. As 8 épocas seguintes (paciência) não trouxeram melhora, e o *early stopping* encerrou o treino antes do limite de 50 épocas. Para $z = 8$, o treino chegou ao limite de 50 épocas, com o menor custo na época 43, isto é, sem melhora nas 7 épocas finais (uma época antes de o critério de paciência atuar). Em ambos os casos a validação já havia se estabilizado, de modo que o limite de 50 épocas não restringiu a convergência. Nos dois casos, o custo cai rapidamente nas primeiras épocas e depois entra em um platô (Figura 1). No início, o custo de validação aparece abaixo do de treino porque o custo de treino é a média acumulada ao longo da própria época, enquanto o de validação é medido ao final dela, com o modelo já atualizado. Para $z = 2$, as curvas são mais ruidosas, com picos isolados na validação de até cerca de 4 nats, compatíveis com a otimização estocástica com $\eta = 10^{-3}$ e lote 128; ao final, treino e validação diferem em apenas 1 a 2 nats (cerca de 252,5 contra 253,5). Para $z = 8$, as curvas são suaves e a diferença entre treino e validação cresce lentamente até cerca de 1,5 nat e se estabiliza. Em nenhum dos modelos a validação voltou a subir enquanto o custo de treino continuava caindo, portanto não houve sobreajuste relevante.

3. Exploração do Espaço Latente

Todas as análises abaixo usam as médias μ do *encoder* sobre as 10.000 imagens de teste. Para $z = 2$, plota-se diretamente o espaço latente; para $z = 8$, usa-se uma projeção por PCA em 2 componentes (Figura 2).

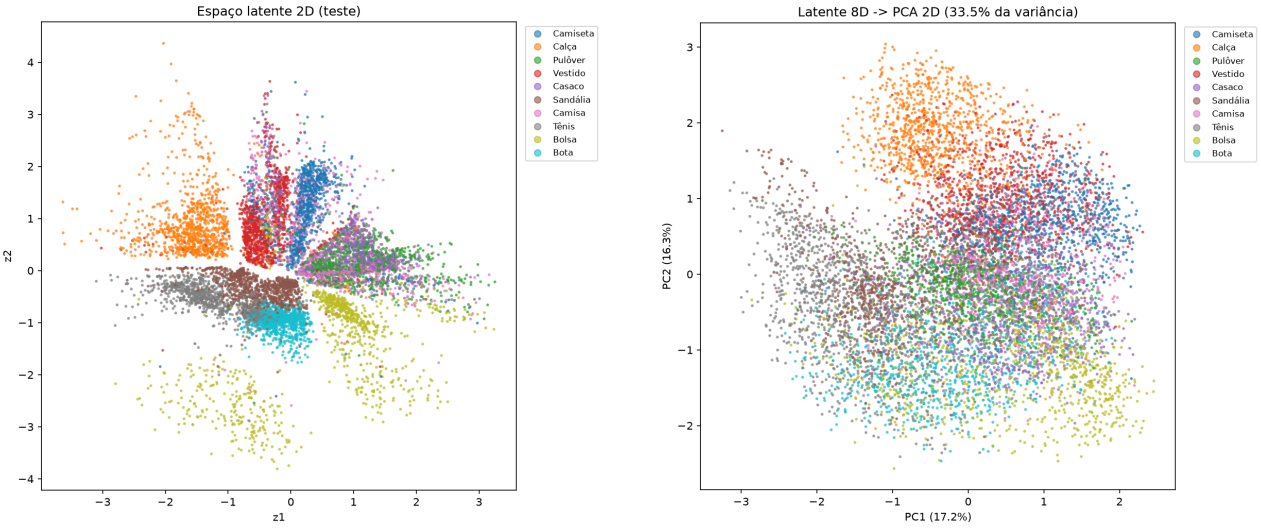


Figure 2: Espaço latente do conjunto de teste, colorido pelo rótulo. Esquerda: $z = 2$. Direita: $z = 8$ projetado por PCA (33,5% da variância).

Variância explicada e dimensões ativas ($z = 8$). A Tabela 5 reúne o diagnóstico por dimensão latente e a decomposição por PCA.

Table 5: Atividade de cada dimensão latente e variância explicada por componente ($z = 8$).

i	KL médio da dim. i	Var(μ_i)	Var. do PCi (%)	Acumulada (%)
1	1,576	0,894	17,23	17,23
2	1,700	0,916	16,31	33,54
3	2,746	1,100	14,96	48,49
4	2,236	1,012	14,64	63,13
5	2,582	1,052	12,93	76,06
6	1,263	0,880	12,80	88,86
7	1,109	0,870	11,14	100,00
8	0,0003	0,0002	0,00	100,00

As colunas de KL e Var(μ_i) referem-se às dimensões latentes originais; as de variância, aos componentes principais.

Separação dos rótulos e agrupamento. A Tabela 6 mostra o *silhouette* dos rótulos e a concordância de um KMeans ($k = 10$) com os rótulos reais, ambos calculados no espaço latente completo.

Table 6: Separação dos rótulos e agrupamento no espaço latente (teste).

z	Silhouette	ARI (KMeans)	NMI (KMeans)
2	0,064	0,384	0,558
8	0,057	0,375	0,498



Figure 3: Originais, reconstruções e amostras geradas a partir de $\mathcal{N}(0, I)$. Superior: $z = 2$. Inferior: $z = 8$.

4. Discussão e Lições Aprendidas

- **Há formação de clusters no espaço latente?** Parcialmente. O KMeans com $k = 10$ concorda de forma moderada com os rótulos (ARI $\approx$ 0,38; NMI de 0,56 para $z = 2$ e 0,50 para $z = 8$), o que indica alguma estrutura, mas longe de grupos bem definidos. Para $z = 2$, as classes ocupam setores em torno da origem (Figura 2): calça, vestido, bolsa e bota formam grupos razoavelmente isolados, e camiseta é compacta, mas toca camisa e vestido.

- **Há separação dos rótulos?** Apenas parcial. O *silhouette* ficou próximo de zero (0,064 e 0,057), o que indica forte sobreposição entre classes. Isso é coerente com o treino não supervisionado: o VAE não recebe os rótulos e organiza o espaço pela reconstrução. As diferenças entre $z = 2$ e $z = 8$ nas métricas de agrupamento são pequenas e vêm de uma única execução (reexecuções da análise alteraram o ARI e o NMI apenas na terceira casa decimal), portanto não sustentam afirmar que um espaço separa melhor que o outro. As maiores sobreposições ocorrem entre pulôver, casaco e camisa, e entre tênis, sandália e bota. No PCA de $z = 8$ a sobreposição é maior, e apenas calça e bolsa permanecem relativamente isoladas.

- **Quanto da variância a projeção ilustra?** Os dois primeiros componentes principais explicam **33,5%** da variância do latente de 8 dimensões (17,2% e 16,3%). Como a variância se distribui de forma quase uniforme por sete componentes, qualquer projeção em 2D descarta cerca de dois terços da informação, e a sobreposição vista na Figura 2 (direita) pode ser em parte efeito da projeção.

- **Colapso parcial no espaço de 8 dimensões.** Uma das dimensões tem KL e variância de μ praticamente nulos (Tabela 5), isto é, o modelo usa na prática 7 das 8 dimensões. As dimensões ativas têm variância próxima de 1, compatível com a priori $\mathcal{N}(0, I)$.

- **Efeito da dimensão latente no custo.** O modelo com $z = 8$ obteve custo de teste menor (238,40 contra 254,01). A decomposição (Tabela 4) mostra que ele reduz o termo de reconstrução em cerca de 21,5 nats ao custo de cerca de 5,9 nats a mais de KL. Na Figura 3, as reconstruções preservam a categoria e a silhueta, mas perdem detalhes finos (estampas, listras, xadrez); com $z = 2$ eles se reduzem a formas genéricas, e com $z = 8$ as imagens são mais nítidas e mantêm detalhes como o comprimento das mangas. As amostras de $z = 2$ são plausíveis, porém genéricas, enquanto as de $z = 8$ são mais variadas (vestido, bolsa com alça, sandália de salto), com algumas imagens borradas ou ambíguas.

- **Limitações.** Resultados de uma única semente; busca aleatória com grid pequeno e apenas 15 épocas por tentativa (a melhor topologia para $z = 2$ é a maior do grid, e a busca pode estar limitada pelas bordas; 4 das 12 combinações não foram testadas, entre elas $[512, 256, 128]$ com $\eta = 5 \times 10^{-4}$ e lote 128); *silhouette* e KMeans usam distância euclidiana, que pode não refletir a geometria real do espaço latente.